

Relatório - Predição de Doença com Machine Learning

Leandro Rosa, Pedro César, Cristian Martins

Março 2026

1 Introdução

Este relatório descreve o desenvolvimento e a avaliação de modelos de aprendizado de máquina aplicados à predição de presença de doença (*Disease*) em indivíduos, a partir de dados clínicos e laboratoriais. O problema é tratado como uma tarefa de classificação binária, na qual cada indivíduo é categorizado como portador ou não de determinada condição de saúde.

O objetivo central é comparar o desempenho de diferentes algoritmos e investigar como a seleção de variáveis influencia a capacidade preditiva de cada modelo. Toda a análise foi conduzida na linguagem R com o auxílio do pacote `caret`, que oferece uma interface unificada para treinamento, validação e comparação de modelos. Foram avaliados seis algoritmos de classificação:

- Regressão Logística (GLM)
- Random Forest
- Support Vector Machines (SVM)
- Naive Bayes
- Redes Neurais Artificiais (ANN)
- Gradient Boosting Machine (GBM)

A escolha desses algoritmos buscou cobrir um espectro amplo de abordagens — de modelos paramétricos simples a métodos ensemble mais sofisticados —, permitindo uma comparação representativa do estado da arte em classificação supervisionada.

2 Metodologia

2.1 Preparação dos Dados

Os dados foram importados de um arquivo Excel e convertidos para um *data frame* no R. A variável alvo foi identificada automaticamente por correspondência de padrões no nome das colunas e renomeada para **Class**, sendo convertida em fator binário com os níveis **NoDisease** e **Disease**. Registros com valores ausentes foram removidos via `na.omit()`, e variáveis do tipo caractere foram convertidas em fatores, garantindo compatibilidade com os algoritmos de classificação utilizados.

2.2 Partição dos Dados

A base foi dividida em dois subconjuntos mutuamente exclusivos: **80% para treinamento**, utilizado no ajuste dos modelos, e **20% para teste**, reservado exclusivamente para a avaliação final do desempenho. A partição foi realizada de forma estratificada em relação à variável alvo, preservando a proporção entre as classes. Uma semente fixa (`seed = 123`) foi definida para assegurar a reprodutibilidade dos experimentos.

2.3 Validação e Otimização

O treinamento foi conduzido com validação cruzada de 10 *folds*, configurada por meio da função `trainControl` do `caret`. A métrica de otimização adotada foi a AUC (*Area Under the ROC Curve*), por ser mais robusta que

a acurácia em cenários com possível desbalanceamento de classes. A busca de hiperparâmetros foi realizada via *Random Search*, estratégia que explora o espaço de parâmetros de forma mais eficiente do que a busca exaustiva em grade.

Todos os atributos numéricos foram padronizados por meio da transformação *z-score*, aplicada automaticamente pelo parâmetro `preProcess` do `caret`:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

Essa normalização é especialmente importante para algoritmos sensíveis à escala dos dados, como SVM e ANN.

2.4 Algoritmos Utilizados

Os seis modelos treinados diferem tanto em sua fundamentação teórica quanto em sua complexidade computacional. A **Regressão Logística** foi incluída como modelo base, por sua simplicidade e interpretabilidade. O **Random Forest** combina múltiplas árvores de decisão via *bagging*, reduzindo variância sem aumentar expressivamente o viés. O **SVM** foi treinado com kernel radial, com ajuste dos parâmetros de regularização C e de largura σ . O **Naive Bayes** opera sob a suposição de independência condicional entre os atributos. A **ANN** utilizada é uma rede com uma camada oculta, com limite de pesos configurado em 5000. Por fim, o **GBM** constrói um ensemble de forma sequencial, corrigindo iterativamente os erros dos modelos anteriores.

2.5 Métricas de Avaliação

O desempenho dos modelos foi mensurado a partir de quatro métricas complementares, extraídas da matriz de confusão e da curva ROC:

- **Acurácia:** proporção de classificações corretas sobre o total
- **Sensibilidade:** capacidade de identificar corretamente os casos positivos
- **Especificidade:** capacidade de identificar corretamente os casos negativos
- **AUC:** área sob a curva ROC, medindo a discriminação global do modelo

A combinação dessas métricas permite uma avaliação mais completa do que a acurácia isolada, especialmente em problemas de diagnóstico clínico onde os custos de falsos negativos e falsos positivos são assimétricos.

3 Resultados e Discussão

3.1 Comparação Geral dos Modelos

A Tabela 1 apresenta o desempenho dos modelos considerando dois cenários: utilização de todas as variáveis e aplicação de seleção de atributos via Information Gain.

Table 1: Comparação de Desempenho dos Modelos

Modelo	Acurácia (%)	Sensibilidade (%)	Especificidade (%)	AUC (%)
Logistic (Todas)	79.37	93.75	64.52	89.72
Random Forest (Todas)	87.30	90.62	83.87	94.96
SVM (Todas)	85.71	96.88	74.19	90.22
Naive Bayes (Todas)	74.60	96.88	51.61	89.72
ANN (Todas)	80.95	84.38	77.42	89.36
GBM (Todas)	88.89	90.62	87.10	94.15
Logistic (CFS)	85.71	93.75	77.42	85.89
Random Forest (CFS)	80.95	87.50	74.19	87.90
SVM (CFS)	82.54	90.62	74.19	87.40
Naive Bayes (CFS)	79.37	96.88	61.29	86.59
ANN (CFS)	80.95	96.88	64.52	88.10
GBM (CFS)	82.54	96.88	67.74	88.31

A análise dos resultados evidencia a superioridade dos modelos baseados em ensemble no cenário com todas as variáveis. O **GBM** alcançou a maior acurácia geral (88,89%), combinada com uma especificidade de 87,10% — o melhor valor entre todos os modelos nessa métrica —, o que indica menor taxa de falsos positivos e maior precisão na identificação de indivíduos saudáveis. O **Random Forest**, por sua vez, obteve a maior AUC (94,96%), refletindo excelente capacidade de discriminação global entre as classes, independentemente do limiar de decisão adotado.

Entre os modelos mais simples, o **SVM** destacou-se com sensibilidade de 96,88%, empatado com o **Naive Bayes** nessa métrica, porém com especificidade significativamente superior (74,19% contra 51,61%). Isso indica que o SVM oferece melhor equilíbrio entre a detecção de casos positivos e a rejeição de negativos. A **ANN**, apesar de apresentar acurácia intermediária (80,95%), foi o modelo com menor sensibilidade (84,38%), o que pode ser limitante em contextos clínicos onde falsos negativos têm alto custo.

3.2 Impacto da Seleção de Variáveis

A transição para o cenário com seleção de variáveis (CFS) produziu efeitos distintos conforme o algoritmo analisado. O caso mais expressivo foi o da **Regressão Logística**, que registrou um ganho de 6,34 pontos percentuais em acurácia — de 79,37% para 85,71% —, sugerindo que o modelo se beneficia diretamente da remoção de atributos ruidosos ou redundantes, que prejudicam sua capacidade de ajuste linear.

Em contrapartida, os modelos ensemble sofreram reduções moderadas de desempenho. O **GBM** caiu de 88,89% para 82,54% em acurácia, e sua AUC recuou de 94,15% para 88,31%. O **Random Forest** apresentou comportamento semelhante, com queda de 87,30% para 80,95% em acurácia e de 94,96% para 87,90% em AUC. Esse padrão é consistente com a natureza desses algoritmos: por serem capazes de modelar interações complexas entre variáveis, eles extraem valor mesmo de atributos com baixo ganho de informação individual, que são eliminados pelo CFS. A seleção de variáveis, portanto, reduz sua capacidade expressiva sem necessariamente simplificar o problema de forma proporcional.

3.3 Evolução da Acurácia

A Figura 1 apresenta a evolução da acurácia de cada algoritmo conforme o número de variáveis aumenta progressivamente de Top 1 até Top 7.




Figure 1: Evolução da Acurácia por Número de Variáveis

O comportamento mais notável no gráfico é o do **Naive Bayes**, que partiu de uma acurácia próxima a 65% com apenas uma variável e apresentou crescimento acentuado até estabilizar em torno de 80% a partir do cenário Top 3, evidenciando forte dependência do conjunto de atributos para seu funcionamento adequado. Os demais algoritmos iniciaram com acurácias já entre 78% e 83%, demonstrando maior capacidade de generalização mesmo com informação restrita.

A partir do cenário **Top 4 Vars**, observa-se uma tendência de estabilização geral, com os ganhos adicionais tornando-se progressivamente marginais. O **GBM** atingiu seu pico de aproximadamente 89% no cenário Top 4, enquanto o **Random Forest** apresentou crescimento mais gradual e consistente, alcançando cerca de 89% apenas no cenário Top 7 — comportamento que reflete sua característica de agregar valor à medida que mais atributos são incorporados.

A **Regressão Logística** surpreendeu positivamente, mantendo desempenho competitivo ao longo de todos os cenários e chegando a superar modelos mais complexos em determinados pontos, o que reforça sua adequação quando o conjunto de variáveis é bem selecionado. De forma geral, o gráfico confirma que as primeiras variáveis — especialmente CRP e Vitamina D — concentram a maior parte da informação preditiva, e que adicionar atributos além do quinto traz retorno decrescente para a maioria dos algoritmos.

3.4 Importância das Variáveis

A Figura 2 apresenta o ranking das variáveis baseado em Information Gain, calculado sobre o conjunto completo de atributos disponíveis na base de dados.




Figure 2: Ranking de Importância das Variáveis

A análise do gráfico evidencia uma concentração expressiva do poder preditivo em apenas quatro variáveis. A **Proteína C-Reativa (CRP)** destacou-se amplamente das demais, com ganho de informação de **0,165** — valor consideravelmente superior ao segundo colocado —, o que a posiciona como o principal biomarcador discriminativo para a presença de doença nesta base. Em seguida, a **Vitamina D** (0,075) e a **Água Extracelular Total (ECF/TBW)** (0,058) também apresentaram contribuição relevante, seguidas pela **AST** (Aspartato Aminotransferase) com 0,033, e por **Lean Mass**, **Água Extracelular (ECW)** e **Total Body Fat Ratio (TBFR)**, com valores próximos a 0,03.

É notável que a grande maioria das variáveis restantes — incluindo indicadores como Triglicerídeos, Colesterol Total, Hemoglobina e IMC — apresentou ganho de informação igual a zero, indicando ausência de poder discriminativo individual para este problema. Esse resultado reforça a hipótese de que a doença investigada possui assinatura clínica bem definida, sendo capturada de forma eficiente por um subconjunto reduzido de biomarcadores metabólicos e de composição corporal.

3.5 Discussão Geral

A análise comparativa entre os algoritmos avaliados revela um padrão claro de superioridade dos modelos baseados em ensemble. O **GBM** e o **Random Forest** consistentemente superaram os demais algoritmos tanto em acurácia quanto em AUC, o que era esperado dado que esses métodos combinam múltiplos classificadores para reduzir variância e viés — característica especialmente vantajosa em bases clínicas, onde as relações entre variáveis tendem a ser não-lineares e complexas.

Um resultado relevante diz respeito ao comportamento dos modelos frente à seleção de variáveis. A aplicação do *Information Gain* mostrou que a capacidade preditiva do conjunto de dados está majoritariamente concentrada em poucos atributos — notadamente CRP, Vitamina D, TBW e AST. Ao testar progressivamente subconjuntos de

variáveis (de Top 1 a Top 7), observou-se que os ganhos de desempenho tornam-se marginais a partir da quarta ou quinta variável, indicando um ponto de saturação informacional. Esse comportamento favorece a construção de modelos mais parcimoniosos, sem comprometimento expressivo das métricas.

Do ponto de vista clínico, o equilíbrio entre sensibilidade e especificidade merece atenção. Modelos com alta sensibilidade, como o **Naive Bayes** e o **SVM**, tendem a minimizar falsos negativos — o que é desejável em triagens de doenças —, porém ao custo de uma especificidade mais baixa. Já o **GBM** apresentou o melhor equilíbrio entre essas duas métricas, o que o torna mais adequado para cenários onde tanto falsos positivos quanto falsos negativos têm implicações relevantes.

Por fim, as escolhas metodológicas adotadas — validação cruzada com 10 *folds*, *Random Search* para otimização de hiperparâmetros e padronização dos dados via *z-score* — contribuíram para a robustez geral dos experimentos, reduzindo o risco de *overfitting* e tornando os resultados mais confiáveis e reprodutíveis.

4 Conclusão

Os experimentos realizados neste trabalho evidenciam que modelos de aprendizado de máquina constituem uma abordagem promissora para a predição de doenças a partir de dados clínicos e laboratoriais. Entre todos os algoritmos avaliados, os modelos baseados em ensemble — especialmente o **GBM** e o **Random Forest** — se destacaram de forma consistente, combinando alta acurácia com boa capacidade discriminativa medida pela AUC.

A seleção de variáveis via Information Gain revelou que a maior parte da informação preditiva está concentrada em poucos atributos, como a Proteína C-Reativa (CRP), a Vitamina D e a Água Corporal Total (TBW). Isso indica que é possível construir modelos enxutos e interpretáveis sem sacrificar expressivamente o desempenho — o que é particularmente relevante em contextos clínicos, onde a transparência do modelo importa tanto quanto sua acurácia.

A utilização de validação cruzada com 10 *folds* e a busca de hiperparâmetros por *Random Search* contribuíram para a robustez e a qualidade da otimização dos modelos, reduzindo o risco de *overfitting* e tornando os resultados mais generalizáveis.

Em síntese, o **GBM** mostrou-se o modelo mais adequado quando o objetivo é maximizar a acurácia, enquanto o **Random Forest** se sobressai pela estabilidade e pelo poder de discriminação. Como perspectiva futura, recomenda-se investigar técnicas de balanceamento de classes, como o SMOTE, bem como explorar arquiteturas mais avançadas — como XGBoost e LightGBM — que podem ampliar ainda mais o potencial preditivo em bases de dados clínicas.