

Relatório-Fraude Bancaria

Leandro Rosa, Cristian Martins

Março 2026

1 Introdução

O presente relatório descreve o desenvolvimento e a avaliação de modelos de aprendizado de máquina aplicados à previsão de inadimplência (*default*) financeira. O objetivo principal é comparar a eficácia de diferentes algoritmos de classificação para identificar o risco de crédito com base em um conjunto de dados histórico.

A análise utiliza a linguagem de programação R e o ecossistema `caret` (*Classification And REgression Training*) para garantir um fluxo de trabalho padronizado. Foram testadas cinco abordagens distintas: Regressão Logística, Random Forest, Support Vector Machines (SVM), Naive Bayes e Redes Neurais Artificiais (ANN). A importância deste estudo reside na capacidade preditiva de minimizar perdas financeiras através da identificação precoce de perfis de risco.

2 Metodologia

A metodologia aplicada segue as etapas fundamentais de descoberta de conhecimento em bases de dados (KDD).

2.1 Preparação dos Dados

Os dados foram extraídos de uma base de dados externa em formato Excel. A variável alvo foi identificada e renomeada para `Class`, sendo convertida em um fator com os níveis `NoDefault` (0) e `Default` (1). Variáveis irrelevantes para a predição, como identificadores de registro (ID), foram removidas para evitar ruído nos modelos.

2.2 Partição e Amostragem

A base de dados foi dividida em dois subconjuntos independentes:

- **Treino (70%):** Utilizado para o ajuste dos parâmetros dos modelos.
- **Teste (30%):** Reservado para a avaliação final e verificação do poder de generalização.

Para garantir a reprodutibilidade dos experimentos e que os resultados possam ser validados futuramente, definiu-se uma semente aleatória fixa (*seed* = 123).

2.3 Algoritmos de Aprendizado

Foram implementados cinco modelos, cada um com configurações específicas de hiperparâmetros e estratégias de ajuste:

1. **Regressão Logística (GLM):** Utilizada como modelo de base (*baseline*).
2. **Random Forest (Ranger):** Implementação de florestas aleatórias com otimização via *threads* paralelas para redução do tempo de processamento.
3. **SVM (Radial Basis Function):** Aplicado com busca em grade (*grid search*) para otimização dos parâmetros C e σ .
4. **Naive Bayes:** Baseado na aplicação do teorema de Bayes com pressuposição de independência condicional.
5. **Redes Neurais (NNET):** Rede neural *feed-forward* de camada oculta única.

2.4 Validação Cruzada e Pré-processamento

Para mitigar o *overfitting* e garantir a robustez dos resultados, utilizou-se a técnica de **Validação Cruzada k-fold** com $k = 5$.

Além disso, todos os dados passaram por um processo de padronização (centralização e escala) para evitar que variáveis com diferentes ordens de grandeza influenciassem desproporcionalmente os modelos, conforme a equação:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

Onde x é o valor original, μ representa a média e σ o desvio padrão do conjunto de treinamento.

2.5 Métricas de Avaliação

O desempenho foi mensurado através da Matriz de Confusão e da análise da curva ROC (*Receiver Operating Characteristic*). As principais métricas calculadas foram:

- **Acurácia:** Proporção de acertos totais sobre o total de casos.
- **Sensibilidade (*Recall*):** Capacidade de identificar corretamente os casos positivos (*Default*).
- **Especificidade:** Capacidade de identificar corretamente os casos negativos (*NoDefault*).
- **AUC (*Area Under the Curve*):** Medida da capacidade de discriminação do modelo entre as classes.

3 Resultados e Discussão

3.1 Análise Exploratória

Antes da aplicação dos modelos preditivos, realizou-se uma análise da distribuição da variável alvo. Conforme apresentado na Figura 1, observa-se um desbalanceamento entre as classes: a quantidade de clientes em conformidade (*NoDefault*) é significativamente superior aos casos de inadimplência (*Default*).

Este cenário de desbalanceamento é um fator crítico, pois pode levar os modelos a apresentarem um viés favorável à classe majoritária. Por esse motivo, a métrica AUC e a Sensibilidade tornam-se tão relevantes quanto a Acurácia total.

3.2 Análise Comparativa dos Modelos

Após o treinamento e validação dos cinco algoritmos propostos, os resultados foram compilados para avaliação de desempenho no conjunto de teste. A Tabela 1 apresenta o resumo das métricas obtidas.

3.3 Discussão dos Resultados

A análise dos resultados revela um comportamento padrão em todos os modelos: uma **Sensibilidade** extremamente elevada (acima de 94%) em contraste com uma **Especificidade** reduzida.

- **Desequilíbrio de Classes:** A alta Sensibilidade indica que os modelos são excelentes em identificar a classe majoritária (*NoDefault*), mas enfrentam dificuldades severas em detectar corretamente os casos de inadimplência (*Default*). O modelo Naive Bayes apresentou a menor Especificidade (14,47%), sugerindo uma tendência quase total de classificar novos clientes como bons pagadores.
- **Melhor Desempenho Global:** O modelo de Redes Neurais (ANN) obteve a maior Acurácia (82,00%) e a melhor Especificidade (36,73%), sendo o modelo mais equilibrado entre os testados. No entanto, em termos de **AUC**, o **Random Forest** destacou-se com 77,20%, indicando uma melhor capacidade de separação entre as classes em diferentes limiares de decisão.

As Figuras 2 e 3 ilustram visualmente a performance dos classificadores.

Pela análise da Curva ROC (Figura 2), observa-se que as curvas de Random Forest e ANN (linhas superiores) dominam as demais, confirmando sua superioridade estatística para este conjunto de dados específico. A baixa Especificidade observada sugere que, em passos futuros, técnicas de *oversampling* (como SMOTE) ou ajuste de custo de erro poderiam ser aplicadas para melhorar a detecção de inadimplentes.



Figure 1: Distribuição das Classes na Base de Dados.

Table 1: Comparativo de Desempenho dos Modelos (%)

Método	Acurácia	Sensibilidade	Especificidade	AUC
Logistic Regression	81,14	97,16	24,72	72,44
Random Forest	81,39	94,84	34,02	77,20
SVM	81,96	96,01	32,51	72,58
Naive Bayes	79,39	97,82	14,47	73,54
ANN	82,00	94,85	36,73	76,85




Figure 2: Curvas ROC Comparativas.




Figure 3: Comparação Geral de Métricas.