

Relatório – Predição de Consumo de Drogas com Machine Learning

Leandro Rosa, Pedro César, Cristian Martins

Abril 2026

1 Introdução

Este relatório descreve o desenvolvimento e a avaliação de modelos de aprendizado de máquina aplicados à predição do consumo de substâncias psicoativas no dataset *Drug Consumption (Quantified)*. O problema é tratado como um conjunto de tarefas de classificação binária independentes: para cada uma das 19 drogas presentes na base, treina-se um modelo que classifica cada indivíduo como usuário (*yes*) ou não-usuário (*no*) da substância.

O objetivo central é identificar qual algoritmo generaliza melhor para cada substância e investigar como o balanceamento de classes influencia a confiabilidade das métricas reportadas. Toda a análise foi conduzida na linguagem R com o auxílio do pacote `caret`. Foram avaliados quatro algoritmos de classificação:

- Regressão Logística (Logistic)
- Random Forest
- Support Vector Machines (SVM)
- Gradient Boosting Machine (GBM)

A escolha desses algoritmos buscou cobrir um espectro de abordagens — de modelos paramétricos simples a métodos ensemble mais sofisticados —, permitindo uma comparação representativa do estado da arte em classificação supervisionada.

2 Metodologia

2.1 Preparação dos Dados

Os dados foram importados e convertidos para um *data frame* no R. Para cada droga, a variável alvo binária foi construída a partir da coluna de consumo correspondente, com os níveis **no** e **yes**. Registros com valores ausentes foram removidos via `na.omit()`, e variáveis categóricas foram convertidas em fatores para compatibilidade com os algoritmos utilizados.

2.2 Balanceamento de Classes

Antes do treinamento, foi realizada uma análise da distribuição das classes para cada droga. Substâncias com distribuição próxima a 50/50 foram consideradas **classes balanceadas**, enquanto aquelas com proporção superior a 65/35 foram sinalizadas como **classes desbalanceadas**, situação em que a acurácia pode estar inflada. Para os casos desbalanceados, foi aplicada a técnica **SMOTE** (*Synthetic Minority Oversampling Technique*) com o objetivo de equalizar a distribuição entre as classes e produzir métricas mais confiáveis. A coluna **SMOTE** na tabela de resultados indica se o oversampling foi aplicado para cada droga.

2.3 Partição dos Dados

A base foi dividida em **80% para treinamento** e **20% para teste**, de forma estratificada em relação à variável alvo. Uma semente fixa (`seed = 123`) foi definida para assegurar a reprodutibilidade dos experimentos.

2.4 Validação e Otimização

O treinamento foi conduzido com validação cruzada de 10 *folds*, configurada por meio da função `trainControl` do `caret`. A métrica de otimização adotada foi a AUC (*Area Under the ROC Curve*), por ser mais robusta que a acurácia em cenários com possível desbalanceamento de classes. A busca de hiperparâmetros foi realizada via *Random Search*.

Todos os atributos numéricos foram padronizados por meio da transformação *z-score*:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

2.5 Algoritmos Utilizados

Os quatro modelos treinados diferem tanto em fundamentação teórica quanto em complexidade computacional. A **Regressão Logística** foi incluída como modelo base, por sua simplicidade e interpretabilidade. O **Random Forest** combina múltiplas árvores de decisão via *bagging*, reduzindo variância. O **SVM** foi treinado com kernel radial, com ajuste dos parâmetros de regularização C e de largura σ . O **GBM** constrói um ensemble de forma sequencial, corrigindo iterativamente os erros dos modelos anteriores.

2.6 Métricas de Avaliação

- **Acurácia:** proporção de classificações corretas sobre o total
- **Sensibilidade:** capacidade de identificar corretamente os usuários
- **Especificidade:** capacidade de identificar corretamente os não-usuários
- **AUC:** área sob a curva ROC, medindo a discriminação global do modelo

3 Resultados e Discussão

3.1 Comparação Geral dos Modelos

A Tabela 1 apresenta, para cada droga, o melhor modelo selecionado e suas respectivas métricas de desempenho no conjunto de teste.

Table 1: Melhor Modelo por Droga – Drug Consumption (Quantified)

Droga	Método	Acurácia (%)	Sensibilidade (%)	Especificidade (%)	AUC (%)	SMOTE
Alcohol	GBM	92.6	23.1	–	95.0	Sim
Amphet	SVM	73.1	74.3	71.1	77.1	Sim
Amyl	Random Forest	80.1	90.1	39.2	77.0	Sim
Benzos	Logistic	68.6	75.8	58.2	74.8	Não
Caff	SVM	92.8	57.1	93.5	76.4	Sim
Cannabis	GBM	82.0	82.3	81.8	89.2	Sim
Choc	Logistic	68.7	57.1	68.9	69.7	Sim
Coke	Random Forest	69.2	77.0	55.5	73.4	Sim
Crack	Logistic	67.3	68.3	57.9	70.5	Sim
Ecstasy	Logistic	73.7	73.4	74.0	82.2	Sim
Heroin	Logistic	75.3	74.6	81.0	81.9	Sim
Ketamine	SVM	69.2	71.0	61.4	75.4	Sim
Legalh	Random Forest	80.0	86.2	71.0	89.7	Não
LSD	GBM	78.2	84.2	64.0	85.0	Sim
Meth	SVM	76.1	76.8	73.5	82.2	Sim
Mushrooms	Logistic	74.2	72.7	76.8	80.6	Sim
Nicotine	Logistic	68.1	66.1	69.0	72.3	Sim
Semer	GBM	91.5	91.7	0.0	84.5	Sim
VSA	Random Forest	84.1	89.4	45.6	82.0	Sim

Os resultados evidenciam grande variação de desempenho entre as substâncias, reflexo das diferentes distribuições de classe e da natureza do padrão de consumo de cada droga. Substâncias com alto consumo na população (ex.: Alcool, Caff) tendem a produzir acurácias elevadas, porém frequentemente às custas de sensibilidade reduzida — o modelo aprende a classificar quase todos como usuários. Já substâncias com distribuição mais equilibrada, como **Cannabis** e **Ecstasy**, apresentam métricas mais balanceadas entre sensibilidade e especificidade.

O **GBM** destacou-se para *Alcohol* (AUC 95,0%), *Cannabis* (AUC 89,2%) e *LSD* (AUC 85,0%), confirmando sua capacidade de capturar padrões complexos de consumo. O **SVM** foi o melhor método para *Amphet*, *Caff*, *Ketamine* e *Meth*. O **Random Forest** liderou em *Amyl*, *Coke*, *Legalh* e *VSA*, enquanto a **Regressão Logística** surpreendeu ao ser o melhor modelo em *Benzos*, *Choc*, *Crack*, *Ecstasy*, *Heroin*, *Mushrooms* e *Nicotine* — sugerindo que para essas substâncias as relações entre os atributos preditivos e o consumo são predominantemente lineares.

No que diz respeito à confiabilidade das métricas, é fundamental considerar o balanceamento de classes de cada substância. **Legalh** (59,58% *no* / 40,42% *yes*) e **Cannabis** (32,89% *no* / 67,11% *yes*) apresentaram classes suficientemente balanceadas, de modo que a acurácia reportada é um indicador confiável do desempenho real — o que explica, em parte, as maiores AUCs observadas para essas substâncias: **Legalh** (89,7%), **Cannabis** (88,7%) e **LSD** (85,0%). Em contrapartida, **LSD** exibe distribuição de 70,45% *no* contra apenas 29,55% *yes*, caracterizando um desbalanceamento relevante onde um classificador trivial já atingiria 70% de acurácia sem qualquer aprendizado. Para esses casos, métricas como AUC e Sensibilidade são mais informativas do que a acurácia isolada.

A aplicação do SMOTE em 17 das 19 drogas demonstra que o desbalanceamento é uma característica predominante deste dataset, e sua mitigação foi essencial para garantir que os modelos aprendessem efetivamente a identificar usuários em vez de simplesmente refletir a distribuição majoritária das classes.

3.2 Acurácia por Droga

A Figura 1 apresenta a acurácia de cada algoritmo para todas as drogas avaliadas, permitindo comparação visual direta entre os quatro métodos.




Figure 1: Acurácia por Droga e por Método (%)

O gráfico ilustra a heterogeneidade do problema: a mesma droga pode ter comportamentos muito distintos entre os algoritmos. Destacam-se os casos de **Caff** e **Semer**, onde o Random Forest atingiu acurácia próxima a 100% — resultado que, entretanto, deve ser interpretado com cautela dado o possível desbalanceamento das classes. O **GBM** apresentou desempenho consistentemente elevado em drogas como Alcool, Cannabis e LSD.

3.3 Sensibilidade por Droga

A Figura 2 apresenta a sensibilidade de cada algoritmo por substância, evidenciando a capacidade de cada método em identificar corretamente os usuários.




Figure 2: Sensibilidade por Droga e por Método (%)

O gráfico de sensibilidade revela padrões relevantes. Para **Crack**, o **Random Forest** atingiu sensibilidade próxima a 97%, destacando-se amplamente dos demais métodos nessa substância. Em contrapartida, para **Alcohol** e **Choc**, todos os algoritmos apresentaram sensibilidade baixa — reflexo do desbalanceamento acentuado das classes. Em substâncias como **Heroin**, **Ecstasy** e **Semer**, os métodos convergiram para sensibilidades elevadas e similares, indicando que essas substâncias apresentam padrões de consumo mais distinguíveis pelos atributos disponíveis.

3.4 Média Geral dos Modelos

A Figura 3 apresenta a média das quatro métricas — Acurácia, Sensibilidade, Especificidade e AUC — agregadas por algoritmo sobre todas as 19 drogas.



Figure 3: Média Geral das Métricas por Método (%)

A análise da média geral revela que os quatro algoritmos apresentaram desempenho bastante similar em todas as métricas, com diferenças inferiores a 10 pontos percentuais. O **Random Forest** obteve a maior acurácia média (aproximadamente 81%), enquanto os demais métodos ficaram entre 74% e 79%. Em Sensibilidade, todos os modelos convergiram para valores próximos a 70%, indicando que a capacidade de detecção de usuários é um desafio comum a todos os algoritmos neste dataset. O **Logistic** destacou-se ligeiramente na Especificidade, e as AUCs médias foram bastante homogêneas entre os métodos — em torno de 79% a 80% —, sugerindo que nenhum algoritmo domina claramente os demais quando avaliado de forma agregada sobre todas as substâncias.

3.5 Discussão Geral

A análise comparativa revela que não existe um único algoritmo dominante para todas as substâncias. O desempenho dos modelos é fortemente condicionado pela natureza de cada droga — em especial pela distribuição de classes e pelos padrões de correlação entre os atributos demográficos/psicológicos e o consumo.

Modelos ensemble como o **GBM** e o **Random Forest** se mostraram mais robustos em substâncias com maior complexidade de padrão (ex.: Cannabis, Alcohol, LSD), enquanto modelos mais simples como a **Regressão Logística** surpreenderam em substâncias com padrões mais lineares (ex.: Heroin, Ecstasy, Mushrooms, Nicotine). O **SVM** com kernel radial demonstrou boa capacidade de separação em casos com fronteiras de decisão não-lineares e moderada sobreposição de classes, como Amphet, Meth e Ketamine.

Um aspecto crítico deste estudo é a baixa especificidade observada em diversas drogas (ex.: Semer com 0%, Amyl com 39,2%, VSA com 45,6%), indicando alta taxa de falsos positivos — o modelo tende a classificar todos como usuários. Esse fenômeno, mesmo após o SMOTE, aponta para limitações dos atributos disponíveis na distinção de não-usuários, e sugere que abordagens de *cost-sensitive learning* podem ser exploradas em trabalhos futuros.

Por fim, a homogeneidade das médias gerais (Figura 3) indica que a escolha do algoritmo ótimo deve ser feita droga a droga, e não de forma global — reforçando a necessidade de pipelines de seleção automática de modelos em problemas multi-alvo como este.

4 Conclusão

Os experimentos realizados neste trabalho demonstram que modelos de aprendizado de máquina são aplicáveis à predição de consumo de substâncias psicoativas a partir de dados demográficos e psicológicos. O problema apresenta alta heterogeneidade entre as substâncias, exigindo que a escolha do melhor algoritmo seja feita individualmente para cada droga.

O **GBM** e o **Random Forest** destacaram-se como os algoritmos mais versáteis, apresentando as maiores AUCs nas substâncias de maior relevância (Cannabis, Legalh, Alcohol). A **Regressão Logística** provou ser competitiva em diversas substâncias — sendo o melhor método em 7 das 19 drogas —, reforçando sua utilidade como modelo base interpretável. O **SVM** mostrou-se especialmente eficaz em substâncias com padrões de consumo de fronteira não-linear.

O desbalanceamento de classes é um desafio central neste dataset, e a aplicação do SMOTE foi determinante para evitar modelos degenerados que ignoram a classe minoritária. A análise da distribuição prévia ao treinamento deve ser considerada etapa obrigatória em problemas desta natureza.

Como perspectivas futuras, recomenda-se investigar técnicas complementares de balanceamento (ex.: ADASYN, *class weighting*), explorar algoritmos como XGBoost e LightGBM, bem como realizar análise de importância de variáveis por droga, de forma a identificar quais atributos demográficos e de personalidade são mais relevantes para a predição de consumo de cada substância.