

Relatório – Predição de Autoimunidade Induzida por Drogas com Machine Learning

Leandro Rosa, Pedro César, Cristian Martins

Abril 2026

1 Introdução

Este relatório descreve o desenvolvimento e a avaliação de modelos de aprendizado de máquina aplicados à predição de autoimunidade induzida por drogas no dataset *Drug Induced Autoimmunity Prediction*. O problema é tratado como uma tarefa de classificação binária: para cada composto presente na base, treina-se um modelo que classifica o composto como indutor de autoimunidade (*yes*) ou não (*no*).

O objetivo central é identificar qual algoritmo generaliza melhor para a predição de autoimunidade induzida por drogas e investigar como o balanceamento de classes e a seleção de variáveis influenciam a confiabilidade das métricas reportadas. Toda a análise foi conduzida na linguagem R com o auxílio do pacote `caret`. Foram avaliados quatro algoritmos de classificação:

- Regressão Logística (Logistic)
- Random Forest
- Support Vector Machines (SVM)
- Gradient Boosting Machine (GBM)

A escolha desses algoritmos buscou cobrir um espectro de abordagens — de modelos paramétricos simples a métodos ensemble mais sofisticados —, permitindo uma comparação representativa do estado da arte em classificação supervisionada aplicada à quimioinformática.

2 Metodologia

2.1 Preparação dos Dados

Os dados foram importados e convertidos para um *data frame* no R. A variável target binária indica se um composto é capaz de induzir autoimunidade, com os níveis **no** e **yes**. Registros com valores ausentes foram removidos via `na.omit()`, e variáveis categóricas foram convertidas em fatores para compatibilidade com os algoritmos utilizados. Os descritores moleculares utilizados como preditores foram derivados das estruturas químicas dos compostos.

2.2 Análise de Componentes Principais (PCA)

Para explorar a estrutura dos dados e avaliar a separabilidade das classes, foi aplicada a Análise de Componentes Principais (PCA) tanto antes quanto após o balanceamento por SMOTE. As Figuras 1 e 2 ilustram a distribuição das amostras nos dois primeiros componentes principais em cada cenário, permitindo avaliar o impacto do oversampling na estrutura do espaço de características.

2.3 Seleção de Variáveis

A seleção de variáveis foi realizada para reduzir a dimensionalidade e melhorar a generalização dos modelos. Foram avaliadas as importâncias dos descritores moleculares por meio de técnicas embarcadas nos algoritmos, com comparação entre os cenários sem e com SMOTE. As Figuras 3 e 4 apresentam os descritores mais relevantes em cada cenário.

2.4 Balanceamento de Classes

Antes do treinamento, foi realizada uma análise da distribuição das classes. O dataset apresenta desbalanceamento entre compostos indutores e não-indutores de autoimunidade. Para mitigar esse problema, foi aplicada a técnica **SMOTE** (*Synthetic Minority Oversampling Technique*) com o objetivo de equalizar a distribuição entre as classes e produzir métricas mais confiáveis.

2.5 Partição dos Dados

A base foi dividida em **80% para treinamento** e **20% para teste**, de forma estratificada em relação à variável alvo. Uma semente fixa (`seed = 123`) foi definida para assegurar a reprodutibilidade dos experimentos.

2.6 Validação e Otimização

O treinamento foi conduzido com validação cruzada de 10 *folds*, configurada por meio da função `trainControl` do `caret`. A métrica de otimização adotada foi a AUC (*Area Under the ROC Curve*), por ser mais robusta que a acurácia em cenários com possível desbalanceamento de classes. A busca de hiperparâmetros foi realizada via *Random Search*.

Todos os atributos numéricos foram padronizados por meio da transformação *z-score*:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

2.7 Algoritmos Utilizados

Os quatro modelos treinados diferem tanto em fundamentação teórica quanto em complexidade computacional. A **Regressão Logística** foi incluída como modelo base, por sua simplicidade e interpretabilidade. O **Random Forest** combina múltiplas árvores de decisão via *bagging*, reduzindo variância. O **SVM** foi treinado com kernel radial, com ajuste dos parâmetros de regularização C e de largura σ . O **GBM** constrói um ensemble de forma sequencial, corrigindo iterativamente os erros dos modelos anteriores.

2.8 Métricas de Avaliação

- **Acurácia:** proporção de classificações corretas sobre o total
- **Sensibilidade:** capacidade de identificar corretamente os compostos indutores de autoimunidade
- **Especificidade:** capacidade de identificar corretamente os compostos não-indutores
- **AUC:** área sob a curva ROC, medindo a discriminação global do modelo

3 Resultados e Discussão

3.1 Análise de Componentes Principais




Figure 1: PCA sem SMOTE – Distribuição das amostras nos dois primeiros componentes principais antes do balanceamento de classes.




Figure 2: PCA com SMOTE – Distribuição das amostras nos dois primeiros componentes principais após o balanceamento de classes por SMOTE.

A comparação entre os dois gráficos de PCA evidencia o impacto do SMOTE na distribuição das amostras. Antes do balanceamento (Figura 1), observa-se a concentração de amostras da classe majoritária, o que pode induzir os modelos a viés em favor desta classe. Após a aplicação do SMOTE (Figura 2), a distribuição torna-se mais equilibrada no espaço de componentes principais, proporcionando melhores condições para o aprendizado dos classificadores.

3.2 Seleção de Variáveis

```
===== CFS ANTES DO SMOTE =====  
>  
> vars_cfs_antes <- cfs(Class ~ ., treino)  
>  
> print(vars_cfs_antes)  
[1] "NumSaturatedCarbocycles" "PEOE_VSA2" "PEOE_VSA7"  
[4] "SMR_VSA10" "SlogP_VSA1" "SlogP_VSA10"  
<
```

Figure 3: Importância das Variáveis sem SMOTE – Descritores moleculares mais relevantes antes do balanceamento de classes.

```
===== CFS DEPOIS DO SMOTE =====  
>  
> vars_cfs_depois <- cfs(Class ~ ., treino_smote)  
>  
> print(vars_cfs_depois)  
[1] "EState_VSA1" "EState_VSA5" "EState_VSA8"  
[4] "NumHDonors" "NumSaturatedCarbocycles" "NumSaturatedHeterocycles"  
[7] "PEOE_VSA10" "PEOE_VSA12" "PEOE_VSA14"  
[10] "PEOE_VSA3" "PEOE_VSA7" "RingCount"  
[13] "SMR_VSA10" "SMR_VSA3" "SMR_VSA9"  
[16] "SlogP_VSA1" "SlogP_VSA10" "SlogP_VSA11"  
[19] "SlogP_VSA5" "VSA_EState10" "fr_ArN"  
[22] "fr_Ar_NH" "fr_CO02" "fr_NH0"  
[25] "fr_NH1" "fr_NH2" "fr_amide"  
[28] "fr_aniline" "fr_aryl_methyl" "fr_benzene"  
[31] "fr_bicyclic" "fr_ether" "fr_methoxy"  
[34] "fr_piperdine"
```

Figure 4: Importância das Variáveis com SMOTE – Descritores moleculares mais relevantes após o balanceamento de classes por SMOTE.

A análise de seleção de variáveis revela quais descritores moleculares são mais informativos para a predição de autoimunidade induzida por drogas. A comparação entre os cenários sem SMOTE (Figura 3) e com SMOTE (Figura 4) permite identificar se o balanceamento de classes altera a relevância relativa dos descritores, o que pode indicar que certas variáveis estavam sendo privilegiadas em função do desbalanceamento original dos dados.

3.3 Comparação Geral dos Modelos

A Tabela 5 apresenta, para cada algoritmo avaliado, as métricas de desenvolvimento obtidas no conjunto de teste para a predição de autoimunidade induzida por drogas, com e sem a aplicação do SMOTE.

	Base	Metodo	Accuracy	Sensitivity	Specificity	AUC
Accuracy	Original	Logistic	72.50	77.78	56.67	69.59
Accuracy1	Original	Random Forest	85.83	94.44	60.00	88.85
Accuracy2	Original	SVM	80.83	94.44	40.00	83.37
Accuracy3	Original	GBM	80.00	94.44	36.67	84.11
Accuracy4	CFS Antes SMOTE	Logistic	55.00	54.44	56.67	61.15
Accuracy11	CFS Antes SMOTE	Random Forest	81.67	88.89	60.00	85.59
Accuracy21	CFS Antes SMOTE	SVM	75.00	77.78	66.67	81.04
Accuracy31	CFS Antes SMOTE	GBM	76.67	88.89	40.00	71.52
Accuracy5	CFS Depois SMOTE	Logistic	64.17	67.78	53.33	63.78
Accuracy12	CFS Depois SMOTE	Random Forest	84.17	96.67	46.67	82.44
Accuracy22	CFS Depois SMOTE	SVM	79.17	90.00	46.67	79.85
Accuracy32	CFS Depois SMOTE	GBM	79.17	93.33	36.67	82.52

Figure 5: Tabela de Resultados – Métricas de desempenho dos modelos para o dataset Drug Induced Autoimmunity Prediction.

3.4 Comparação da AUC entre os Modelos




Figure 6: Comparação da AUC por Método – Área sob a curva ROC para cada algoritmo avaliado no dataset Drug Induced Autoimmunity Prediction.

A Figura 6 apresenta a comparação da AUC entre os quatro algoritmos avaliados. A AUC é a métrica central de avaliação neste estudo, por ser mais robusta ao desbalanceamento de classes do que a acurácia isolada. Os modelos foram avaliados sendo tanto no cenário sem SMOTE quanto no cenário com SMOTE, permitindo quantificar o ganho em termos de capacidade discriminativa.

3.5 Discussão Geral

Os resultados obtidos demonstram que o balanceamento de classes via SMOTE tem impacto relevante no desempenho dos modelos para o dataset *Drug Induced Autoimmunity Prediction*. O desbalanceamento original entre compostos indutores e não-indutores de autoimunidade é uma característica central deste problema, e sua mit-

igação é essencial para garantir que os modelos aprendam efetivamente a identificar compostos de risco em vez de refletir a distribuição majoritária das classes.

A análise de PCA indica que os dados possuem estrutura de separabilidade entre as classes, ainda que com sobreposição, justificando o uso de algoritmos com diferentes capacidades de modelagem de fronteiras de decisão. A seleção de variáveis reforça que um subconjunto dos descritores moleculares disponíveis é suficiente para capturar os padrões relevantes, reduzindo o risco de sobreajuste e melhorando a interpretabilidade dos modelos.

Modelos ensemble como o **GBM** e o **Random Forest** tendem a apresentar maior robustez em problemas com descritores moleculares de alta dimensionalidade, ao passo que a **Regressão Logística** oferece maior interpretabilidade — aspecto relevante em aplicações de quimiinformática onde a compreensão dos mecanismos preditivos é igualmente importante ao desempenho preditivo. O **SVM** com kernel radial demonstra boa capacidade de separação em casos com fronteiras de decisão não-lineares, comuns em datasets de descritores moleculares.

4 Conclusão

Os experimentos realizados neste trabalho demonstram que modelos de aprendizado de máquina são aplicáveis à predição de autoimunidade induzida por drogas a partir de descritores moleculares. O balanceamento de classes via SMOTE mostrou-se uma etapa essencial no pré-processamento, com impacto direto na qualidade das métricas e na capacidade dos modelos de identificar corretamente os compostos indutores de autoimunidade.

A análise de componentes principais e a seleção de variáveis fornecem perspectivas complementares sobre a estrutura dos dados e os descritores mais relevantes para o problema. A comparação entre múltiplos algoritmos permite identificar qual abordagem generaliza melhor para este dataset específico.

Como perspectivas futuras, recomenda-se investigar técnicas complementares de balanceamento (ex.: ADASYN, *class weighting*), explorar algoritmos como XGBoost e LightGBM, bem como realizar análise de importância de variáveis com métodos agnósticos ao modelo (ex.: SHAP), de forma a identificar quais descritores moleculares são mais determinantes para a indução de autoimunidade e contribuir para o entendimento mecanístico do fenômeno.