

Relatório – Comparação de Modelos de Classificação no Dataset Indian Liver Patient

Leandro Rosa, Pedro César, Cristian Martins

Abril 2026

1 Introdução

Este relatório descreve o desenvolvimento e a avaliação de modelos de aprendizado de máquina aplicados à predição de doença hepática no dataset *Indian Liver Patient Dataset (ILPD)*. O problema é tratado como uma tarefa de classificação binária: para cada paciente presente na base, treina-se um modelo que classifica o indivíduo como portador de doença hepática (*sim*) ou não (*não*).

O objetivo central é comparar dois scripts de análise desenvolvidos sequencialmente, identificando como o refinamento da metodologia – em especial a aplicação de balanceamento de classes via SMOTE e a análise de componentes principais – impacta as métricas de desempenho dos modelos. Toda a análise foi conduzida na linguagem R com o auxílio do pacote `caret`. Foram avaliados quatro algoritmos de classificação:

- Regressão Logística (Logistic)
- Random Forest
- Support Vector Machines (SVM)
- Gradient Boosting Machine (GBM)

A escolha desses algoritmos buscou cobrir um espectro de abordagens — de modelos paramétricos simples a métodos ensemble mais sofisticados —, permitindo uma comparação representativa do estado da arte em classificação supervisionada aplicada a dados clínicos.

2 Metodologia

2.1 Preparação dos Dados

Os dados foram importados e convertidos para um *data frame* no R. A variável alvo binária indica se o paciente é portador de doença hepática. Registros com valores ausentes foram removidos via `na.omit()`, e variáveis categóricas foram convertidas em fatores para compatibilidade com os algoritmos utilizados.

2.2 Linha de Base – Primeiro Script

O primeiro script representa a abordagem inicial, sem balanceamento de classes e sem análise exploratória aprofundada da estrutura dos dados. Os modelos foram treinados directamente sobre os dados originais, com validação cruzada e padronização dos atributos numéricos. Os resultados desse script, apresentados na Figura 1, constituem a **linha de base** para comparação com a metodologia aprimorada.

Metodo	ACC	SENS	SPEC
<chr>	<dbl>	<dbl>	<dbl>
ANN	67.2	83.9	26
Gaussian NB	60.3	54.8	74
Generalized Linear Model	71.8	100	2
Random Forest	72.4	85.5	40
SVM	71.3	100	0
SVM Class Weights	71.3	100	0

Figure 1: Resultados da Linha de Base – Métricas de desempenho dos modelos obtidas no primeiro script, sem balanceamento de classes (SMOTE).

Como observado na Figura 1, os modelos da linha de base apresentam acurácia relativamente elevada, reflexo direto do desbalanceamento de classes presente no dataset: ao prever majoritariamente a classe dominante, o modelo infla a acurácia sem necessariamente aprender a discriminar adequadamente os casos positivos. Essa é uma limitação central que motivou o desenvolvimento do segundo script.

2.3 Metodologia Aprimorada – Segundo Script

O segundo script incorporou um pipeline mais robusto, com as seguintes etapas adicionais em relação à linha de base:

- **Análise de Componentes Principais (PCA):** aplicada antes e após o balanceamento para avaliar a separabilidade das classes no espaço de características.
- **Balanceamento de Classes via SMOTE:** aplicação da técnica *Synthetic Minority Oversampling Technique* para equalizar a distribuição entre as classes.
- **Validação Cruzada de 10 folds** com métrica de otimização baseada em **AUC**, mais robusta ao desbalanceamento do que a acurácia.
- **Random Search** para otimização de hiperparâmetros.
- **Padronização z-score** de todos os atributos numéricos:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

2.4 Partição dos Dados

A base foi dividida em **80% para treinamento** e **20% para teste**, de forma estratificada em relação à variável alvo. Uma semente fixa (*seed* = 123) foi definida para assegurar a reprodutibilidade dos experimentos.

2.5 Métricas de Avaliação

- **Acurácia:** proporção de classificações corretas sobre o total
- **Sensibilidade:** capacidade de identificar corretamente os pacientes portadores de doença hepática (verdadeiros positivos)
- **Especificidade:** capacidade de identificar corretamente os pacientes sem doença hepática (verdadeiros negativos)
- **AUC:** área sob a curva ROC, medindo a discriminação global do modelo

3 Resultados e Discussão

3.1 Análise de Componentes Principais (PCA)




Figure 2: PCA dos Indivíduos – Distribuição das amostras nos dois primeiros componentes principais antes do balanceamento de classes.




Figure 3: PCA pós-SMOTE – Distribuição das amostras nos dois primeiros componentes principais após o balanceamento de classes por SMOTE.

A comparação entre as Figuras 2 e 3 evidencia o impacto do SMOTE na distribuição das amostras. Antes do balanceamento (Figura 2), observa-se a concentração de amostras da classe majoritária, o que pode induzir os modelos a viés em favor dessa classe. Após a aplicação do SMOTE (Figura 3), a distribuição torna-se mais equilibrada no espaço de componentes principais, proporcionando melhores condições para o aprendizado dos classificadores.

3.2 Resultados com SMOTE

	Base	Metodo	Acc	Sen	Spe	Bal	AUC
	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	CFS Antes	ANN	59.9	51.9	79.8	65.9	69.8
2	CFS Antes	GBM	61.6	53.2	82.2	67.7	72.7
3	CFS Antes	Logistic	59.9	47.4	90.8	69.1	72.6
4	CFS Antes	Naïve Bayes	57.1	43.3	91.4	67.4	71.4
5	CFS Antes	Random Forest	66.2	65.8	67	66.4	73.5
6	CFS Antes	SVM	62.8	54.8	82.4	68.6	72.7
7	CFS Depois	ANN	62.2	58.0	72.8	65.4	69.3
8	CFS Depois	GBM	65.5	67.3	60.8	64.1	70.2
9	CFS Depois	Logistic	60.8	49.1	89.6	69.4	72.9
10	CFS Depois	Naïve Bayes	59.8	48.8	87.2	68	71.1
11	CFS Depois	Random Forest	67.3	66.0	70.4	68.2	75.5
12	CFS Depois	SVM	63.0	58.4	74.6	66.5	70.6
13	Original	ANN	62.8	58.6	73	65.8	70.3
14	Original	GBM	63.0	56.4	79.2	67.8	73.1
15	Original	Logistic	62.2	51.0	90	70.5	74.9
16	Original	Naïve Bayes	61.2	51.4	85.4	68.4	71.3
17	Original	Random Forest	66.7	63.6	74.6	69.1	76.0
18	Original	SVM	63.2	55.8	81.4	68.6	73.4

Figure 4: Resultados com SMOTE – Métricas de desempenho dos modelos após o balanceamento de classes por SMOTE no dataset Indian Liver Patient.

A Figura 4 apresenta as métricas dos modelos obtidas no segundo script, após a aplicação do SMOTE. Em comparação com a linha de base (Figura 1), observa-se um **trade-off esperado e clinicamente relevante**: a acurácia geral apresentou **redução** em relação ao primeiro script, ao passo que a **sensibilidade** (capacidade de detectar corretamente os pacientes doentes) e a **especificidade** (capacidade de identificar corretamente os pacientes saudáveis) apresentaram **melhora significativa**.

Esse comportamento é característico de cenários com desbalanceamento de classes: no primeiro script, a acurácia elevada era inflada pela predição majoritária da classe dominante, mascarando a real incapacidade dos modelos de identificar os casos positivos. Com o balanceamento via SMOTE, os modelos passaram a aprender de forma mais equilibrada entre as classes, resultando em ganhos efetivos de sensibilidade e especificidade – métricas de maior relevância clínica em problemas de diagnóstico médico –, ainda que à custa de uma acurácia global ligeiramente menor. Em contextos de saúde, um modelo com menor acurácia, mas com maior sensibilidade e especificidade, é substancialmente mais útil e confiável do que um modelo com alta acurácia obtida à custa do viés para a classe majoritária.

3.3 Comparação da AUC entre os Modelos




Figure 5: Comparação da AUC por Método – Área sob a curva ROC para cada algoritmo avaliado no dataset Indian Liver Patient, com e sem SMOTE.

A Figura 5 apresenta a comparação da AUC entre os quatro algoritmos avaliados nos dois scripts. A AUC é a métrica central de avaliação neste estudo, por ser mais robusta ao desbalanceamento de classes do que a acurácia isolada. A comparação permite quantificar, de forma independente do limiar de decisão, o ganho real em capacidade discriminativa proporcionado pela metodologia aprimorada.

3.4 Discussão Geral

Os resultados obtidos demonstram que o balanceamento de classes via SMOTE tem impacto relevante e, em alguns aspectos, contraditório com as expectativas superficiais: embora a acurácia global tenha **diminuído** no segundo script em relação à linha de base, esse resultado não deve ser interpretado como piora do modelo. Pelo contrário, a **melhora da sensibilidade e da especificidade** no segundo script indica que os modelos passaram a tomar decisões mais equilibradas e clinicamente coerentes.

A queda na acurácia reflete a correção do viés que inflava artificialmente essa métrica no primeiro script: ao forçar o aprendizado equilibrado entre as classes via SMOTE, o modelo abre mão de acertos fáceis na classe majoritária para ganhar capacidade real de discriminação entre as classes. Para aplicações de diagnóstico hepático – onde tanto falsos negativos (pacientes doentes não identificados) quanto falsos positivos (pacientes saudáveis incorretamente classificados como doentes) têm consequências clínicas relevantes – a sensibilidade e a especificidade são métricas substancialmente mais importantes do que a acurácia global.

Modelos ensemble como o **GBM** e o **Random Forest** tendem a apresentar maior robustez em problemas com múltiplos atributos clínicos, ao passo que a **Regressão Logística** oferece maior interpretabilidade. O **SVM** com kernel radial demonstra boa capacidade de separação em casos com fronteiras de decisão não-lineares.

4 Conclusão

Os experimentos realizados neste trabalho demonstram que o refinamento metodológico introduzido no segundo script – especialmente o balanceamento de classes via SMOTE e a otimização por AUC – produziu modelos mais confiáveis para a predição de doença hepática no dataset *Indian Liver Patient Dataset*.

O principal achado desta comparação é o **trade-off entre acurácia e as demais métricas**: enquanto o primeiro script apresentou acurácia superior, o segundo script obteve **melhores resultados de sensibilidade e especificidade**, métricas de maior relevância clínica. Esse resultado reforça que a acurácia, isoladamente, é uma métrica insuficiente para avaliar modelos de classificação em datasets desbalanceados, e que o uso do SMOTE combinado com a otimização por AUC é uma estratégia eficaz para produzir modelos mais justos e clinicamente úteis.

Como perspectivas futuras, recomenda-se investigar técnicas complementares de balanceamento (ex.: ADASYN, *class weighting*), explorar algoritmos como XGBoost e LightGBM, bem como realizar análise de importância de variáveis com métodos agnósticos ao modelo (ex.: SHAP), de forma a identificar quais atributos clínicos são mais determinantes para o diagnóstico de doença hepática.